ธนกิจ เหล่ายาวิระ 600632014

## **Computer Assignment 2.2**

# า.รายละเอียดของทฤษฎีหรือวิธีการต่าง ๆ ที่ใช้

- 1. Levenshtein Distance คือ ขั้นตอนวิธีการนี้จะเป็นการนำชุดอักขระ 2 ชุด มาเปรียบเทียบจำนวนความแตกต่างกัน โดยจะพิจารณาดังนี้
- <u>การแทรก</u> เป็นการนำเอาอักขระตัวใด ๆ มา เพื่อให้ชุดอักขระชุดนั้นเหมือนกับอีกชุดอักขระหนึ่งในภายหลัง
- <u>การตัดออก</u> เป็นการตัดอักขระออกครั้งละ 1 ตัว จากชุดอักขระตัวหนึ่ง เพื่อให้ชุดอักขระชุดนั้นเหมือนกับอีกชุดอักขระ หนึ่งในภายหลัง
- <u>การแทนที่</u> เป็นการนำอักขระของชุดอักขระหนึ่งไปแทนอักขระของอีกชุดอักขระหนึ่ง เพื่อให้ชุดอักขระชุดนั้นเหมือนกับอีก ชุดอักขระหนึ่งในภายหลัง
- 2. ใช้ NodeJS ในการพัฒนาซอฟท์แวร์

### 2. Algorithm

- N unlabeled finite strings  $X=\{\alpha_k | k=1,...,N\}$
- Select number of clusters  $1 \le C \le N$

set maximum number of iteration (T)

set termination measure  $\rightarrow \varepsilon_t = ||\mathbf{V}_t - \mathbf{V}_{t-1}||$  (V is a set of string prototypes)

termination threshold: ε

- Initial string prototype  $V_0 = (\alpha'_{1,0}, \dots, \alpha'_{C,0})$  where  $\alpha'_{i,0} \in X$  and  $i=1,\dots,C$
- t = 0
- Repeat
  - t = t+1
  - For k=1:N
    - For i=1:C

• 
$$D_{ik,t} = \delta^2(\alpha_k, \alpha'_{i,t-1})$$

- End For
- End For
- For i=1:C
  - $n_{i,t} = 0$
  - For k=1:N

$$u_{ik,t} = \begin{cases} 1 & \text{if } D_{ik,t} \le D_{jk,t} & \text{for } j \ne i \\ 0 & \text{else} \end{cases}$$

$$\bullet \qquad n_{i,t} = n_{i,t} + u_{ik,t}$$

- End For
- End For
- For i=1:C

$$q = \underset{1 \le j \le n_{i,j}}{\operatorname{arg\,min}} \left\{ c_{i,j} = \sum_{s=1}^{N} \left( \frac{\delta \left( u_{ij,s} \alpha_{j}, u_{is,j} \alpha_{s} \right)}{n_{i,j}} \right) \right\}$$

- $-\alpha'_{i,t}=\alpha_q$
- End For
- Until  $(t=T \text{ or } \varepsilon_t \leq \varepsilon)$

#### วิธีการทดลอง

- 1. รันโปรแกรมจากการสุ่ม prototype ใน train data
- 2. น้ำ prototype ที่เสถียรแล้วจาก train data ไปเป็น prototype เริ่มต้นของ test data
- 3. สังเกตผลการทดลอง

#### 4. ผลการทดลอง

```
Train data
                                                     Test data
                                                      round: 1
 round: 1
                                                      current prototype: 1850,245,1152 (index)
 current prototype : 2047,40,1627 (index)
cluster 1 count: 435
                                                      cluster 1 count: 921
 cluster 2 count: 388
                                                      cluster 2 count: 472
 cluster 3 count: 1377
                                                      cluster 3 count: 807
                                                      round: 2
 current prototype: 2023,225,1196 (index)
                                                      current prototype: 1825,322,1050 (index)
 et: 18.681541692269406
                                                      et: 0
 cluster 1 count: 724
                                                      cluster 1 count: 949
 cluster 2 count: 461
                                                      cluster 2 count: 433
 cluster 3 count: 1015
                                                      cluster 3 count: 818
                                                       _____
 current prototype : 1850,245,1196 (index)
 et: 11.681541692269406
 cluster 1 count: 815
 cluster 2 count: 531
 cluster 3 count: 854
 round: 4
 current prototype: 1850,245,1168 (index)
 et: 1
 cluster 1 count: 889
 cluster 2 count: 489
 cluster 3 count: 822
 current prototype : 1850,245,1152 (index)
 et: 8
 cluster 1 count: 918
 cluster 2 count: 453
 cluster 3 count: 829
 round: 6
 current prototype: 1850,245,1152 (index)
 cluster 1 count: 918
 cluster 2 count: 453
 cluster 3 count: 829
```

round: 1 current prototype : 268,972,125 (index) cluster 1 count: 415 cluster 2 count: 1630 cluster 3 count: 155 round: 2 current prototype: 350,1496,49 (index) cluster 1 count: 568 cluster 2 count: 1494 cluster 3 count: 138 round: 3 current prototype : 546,1496,49 (index) et: 4.248456731316587 cluster 1 count: 650 cluster 2 count: 1382 cluster 3 count: 168 round: 4 current prototype : 1108,1578,49 (index) et: 6.30337936338692 cluster 1 count: 918 cluster 2 count: 1083 cluster 3 count: 199 round: 5 current prototype: 1152,1825,73 (index) et: 5.3386326591070805 cluster 1 count: 1009 cluster 2 count: 923 cluster 3 count: 268 ----round: 6 current prototype: 1152,1850,225 (index) et: 21.213203435596427 cluster 1 count: 960 cluster 2 count: 891 cluster 3 count: 349 round: 7 current prototype: 1152,1850,225 (index) et: 0 cluster 1 count: 960 cluster 2 count: 891 cluster 3 count: 349 -----

round: 1 current prototype: 1152,1850,225 (index) cluster 1 count: 918 cluster 2 count: 886 cluster 3 count: 396 round: 2 current prototype: 1050,1847,322 (index) cluster 1 count: 897 cluster 2 count: 903 cluster 3 count: 400 round: 3 current prototype: 1050,1825,322 (index) cluster 1 count: 884 cluster 2 count: 916 cluster 3 count: 400 round: 4 current prototype: 1050,1825,322 (index) et: 0 cluster 1 count: 884 cluster 2 count: 916 cluster 3 count: 400

round: 1 round: 1 current prototype : 2001,1108,1634 (index) current prototype : 2190,1458,1465 (index) cluster 1 count: 420 cluster 1 count: 630 cluster 2 count: 1110 cluster 2 count: 1701 cluster 3 count: 460 cluster 3 count: 79 round: 2 round: 2 current prototype : 2023,1152,1465 (index) current prototype : 1882,1005,1615 (index) et: 15.684387141358123 et: 10 cluster 1 count: 581 cluster 1 count: 631 cluster 2 count: 1005 cluster 2 count: 1253 cluster 3 count: 614 cluster 3 count: 316 round: 3 current prototype : 1882,1005,1359 (index) current prototype : 2001,1022,1634 (index) et: 3.6843871413581226 et: 10 cluster 1 count: 671 cluster 1 count: 585 cluster 2 count: 916 cluster 2 count: 1079 cluster 3 count: 536 cluster 3 count: 613 round: 4 current prototype : 1882,1005,1359 (index) current prototype : 2001,1108,1634 (index) et: 12 et: 0 cluster 1 count: 585 cluster 1 count: 671 cluster 2 count: 1006 cluster 2 count: 916 cluster 3 count: 609 cluster 3 count: 613 round: 5 current prototype : 2001,1108,1634 (index) et: 0 cluster 1 count: 585 cluster 2 count: 1006 cluster 3 count: 609 \_\_\_\_\_

## 4. สรุปผลการทดลอง

เมื่อใช้ prototype จาก train data มาเป็น prototype เริ่มต้นของ test data แล้ว จำนวนรอบของการจัดกลุ่ม จะน้อยลง เพราะ prototype เริ่มต้นของ test มีความเสถียรแล้ว Code: String Grammar Hard C-Means (NodeJS)

```
let fs = require('fs')
const levenshtein = require('js-levenshtein');
const cNum = 3 //Change number of clusters here
const maxT = 100
let e = 0.005
let dataSet = 'da'
const fetchData = new Promise((resolve) => {
    let res = []
    for (let i = 1; i <= 22; i++) {
        let input = fs.readFileSync(`chrom/dif${i}${dataSet}`,
'utf8').trim().split('\r\n').map(x => x.split('\t'))
        res = res.concat(input)
    resolve(res)
})
const main = async () => {
    let prototype = []
    let p1 = null
    let p2 = null
    let v1 = 0
    let v2 = 0
    let cluster = []
    let eCal = 999999
    let sourceData = await fetchData.then((values) => {
        return values.map((value) => value[1])
    })
    // random choose prototype
    if (prototype.length === 0) {
        for (let i = 0; i < cNum; i++) {
            let rand = Math.floor(Math.random() * sourceData.length)
            prototype.push(rand)
    for (let i = 0; i < cNum; i++) {
        cluster.push([])
    p1 = prototype
    for (let t = 0; t < maxT; t++) {</pre>
        cluster = []
        for (let i = 0; i < cNum; i++) {
            cluster.push([])
```

```
for (let n = 0; n < sourceData.length; n++) {</pre>
            let minDist = 9999999
            let chooseC = null
            for (let i = 0; i < cNum; i++) {
                 let dist = await levenshtein(sourceData[n],
sourceData[prototype[i]])
                if (dist < minDist) {</pre>
                     chooseC = i
                     minDist = dist
                 }
            cluster[chooseC].push(n)
        console.log(`round: ${t + 1}`)
        prototype = []
        let minDist = 999999
        let chooseV = null
        let sumDist = 0
        let cen = 0
        for (let i = 0; i < cNum; i++) {
            minDist = 999999
            chooseV = null
            for (let j = 0; j < cluster[i].length; j++) {</pre>
                sumDist = 0
                 for (let k = 0; k < cluster[i].length; k++) {</pre>
                     if (cluster[i][j] != cluster[i][k]) {
                         let dist = await
levenshtein(sourceData[cluster[i][j]], sourceData[cluster[i][k]])
                         sumDist = sumDist + dist
                 cen = sumDist / cluster[i].length
                 if (cen < minDist) {</pre>
                     chooseV = cluster[i][j]
                     minDist = cen
                 }
            prototype.push(chooseV)
        if (t === 0) {
            p2 = prototype
        else if (t === 1) {
            p1 = p2
            p2 = prototype
        }
        else {
```

```
p1 = p2
           p2 = prototype
       if (t > 0) {
           let sumPDist = 0
           for (let i = 0; i < cNum; i++) {
               let dist = await levenshtein(sourceData[p2[i]],
sourceData[p1[i]])
               sumPDist = sumPDist + Math.pow(dist, 2)
           if (t === 0) {
               v1 = 0
               v2 = Math.sqrt(sumPDist)
           else {
               v1 = v2
               v2 = Math.sqrt(sumPDist)
               eCal = Math.abs(v1 - v2)
       }
       console.log(`current prototype : ${p1} (index)`)
       if (t != 0) console.log(`et: ${eCal}`)
       for (let c = 0; c < cNum; c++) {
           console.log(`cluster ${c + 1} count: ${cluster[c].length}`)
       console.log(`========== \n`)
       if (t > 0 && eCal <= e) break
   }
main()
```